

Méthodes de factorisation profonde pour la séparation de profils de pollution

Matthieu PUIGT Gilles DELMAIRE Gilles ROUSSEL

Univ. Littoral Côte d'Opale, EA 4491 – LISIC, F-62228 Calais, France

`firstname.LASTNAME@univ-littoral.fr`



Avant-propos : la factorisation matricielle (1)

Vous savez tous résoudre un système d'équations

$$\begin{cases} 2 \cdot s_1 + 3 \cdot s_2 & = 5 \\ 3 \cdot s_1 - 2 \cdot s_2 & = 1 \end{cases} \quad (1)$$

Si on note l'équation sous forme matricielle avec A , \underline{s} et \underline{x} la matrice et les vecteurs :

$$A = \begin{bmatrix} 2 & 3 \\ 3 & -2 \end{bmatrix}, \underline{s} = [s_1, s_2]^T \text{ et } \underline{x} = [5, 1]^T$$

Alors l'Eq. (1) devient

$$\underline{x} = A \cdot \underline{s}$$

dont la solution est :

$$\underline{s} = A^{-1} \cdot \underline{x} = [1, 1]^T$$

Trouver \underline{s} en fonction de \underline{x} s'appelle un **problème inverse** car on doit inverser l'opérateur A .

Avant-propos : la factorisation matricielle (1)

Vous savez tous résoudre un système d'équations

$$\begin{cases} 2 \cdot s_1 + 3 \cdot s_2 + \dots + 7 \cdot s_5 = 5 \\ 3 \cdot s_1 - 2 \cdot s_2 + \dots + 2 \cdot s_5 = 1 \end{cases} \quad (1)$$

Si on note l'équation sous forme matricielle avec A , \underline{s} et \underline{x} la matrice et les vecteurs :

$$A = \begin{bmatrix} 2 & 3 & \dots & 7 \\ 3 & -2 & \dots & 2 \end{bmatrix}, \underline{s} = [s_1, s_2]^T \text{ et } \underline{x} = [5, 1]^T$$

Alors l'Eq. (1) devient

$$\underline{x} = A \cdot \underline{s}$$

dont la solution est :

$$\underline{s} = ???$$

Trouver \underline{s} en fonction de \underline{x} s'appelle un **problème inverse** car on doit inverser l'opérateur A .

Comment résoudre ce type de problème si ???

- Il y a plus d'inconnues que d'équations (problème inverse **mal posé**)

Avant-propos : la factorisation matricielle (1)

Vous savez tous résoudre un système d'équations

$$\begin{cases} ? \cdot s_1 + ? \cdot s_2 & = 5 \\ ? \cdot s_1 + ? \cdot s_2 & = 1 \end{cases} \quad (1)$$

Si on note l'équation sous forme matricielle avec A , \underline{s} et \underline{x} la matrice et les vecteurs :

$$A = \begin{bmatrix} ? & ? \\ ? & ? \end{bmatrix}, \underline{s} = [s_1, s_2]^T \text{ et } \underline{x} = [5, 1]^T$$

Alors l'Eq. (1) devient

$$\underline{x} = A \cdot \underline{s}$$

dont la solution est :

$$\underline{s} = A^{-1} \cdot \underline{x} = ?$$


Trouver \underline{s} en fonction de \underline{x} s'appelle un **problème inverse** car on doit inverser l'opérateur A .

Comment résoudre ce type de problème si ???

- Il y a plus d'inconnues que d'équations (problème inverse **mal posé**)
- Si on ne connaît pas l'opérateur A (approche **aveugle** de déconvolution, égalisation, localisation, séparation de sources)

Avant-propos : la factorisation matricielle (2)

Enormément de problèmes, en *machine learning* et en traitement du signal, peuvent s'écrire sous forme de systèmes d'équations $X \approx A \cdot S$:




Approximation de matrices de faible rang

X matrice bruitée ou à trous, A matrice de poids, S matrice de variables latentes

- *Topic modeling*
- Filtrage collaboratif (par ex: problème Netflix)
- Etalonnage de capteurs mobiles (Thèse de Clément Dorffer)



Avant-propos : la factorisation matricielle (2)

Enormément de problèmes, en *machine learning* et en traitement du signal, peuvent s'écrire sous forme de systèmes d'équations $X \approx A \cdot S$:




localisation/séparation de sources

X matrice de données observées, A matrice de mélange, S matrice des sources

- Si A estimée (et géométrie du réseau de capteurs connue)
 - ⇒ estimation de mélanges (localisation de sources )
- Si S estimée (et géométrie du réseau de capteurs connue)
 - ⇒ séparation de sources (traitement d'antennes )


Avant-propos : la factorisation matricielle (3)

- Dans beaucoup de problèmes, les matrices dans $X \approx A \cdot S$ sont non-négatives
- ⇒ Contraintes de non-négativité sur A et/ou S amène une meilleure interprétabilité
- ⇒ **Non-negative Matrix Factorization (NMF)**



NMF appliquée à des visages (source : Lee & Seung, 1999)

Séparation de sources chimiques




- Acquisition de particules fines
- n échantillons analysés par les chimistes
- Données observées rangées dans une matrice (un tableau) X de taille $n \times m$ représentant les concentrations de m espèces chimiques (en ng/m^3)
- Données observées sont des mélanges de "profils"

$$X \simeq A \cdot S$$

- ➔ A est la matrice $n \times p$ de contribution (ng/m^3)
- ➔ S est la matrice $p \times m$ de profils (proportions relatives d'espèces chimiques) de sources (ng/ng)

Analyse de l'existant



NMF informée

- NMF classique ne fournit pas de solution convenable
- Information complémentaire :
 - Mesure de confiance dans les données X (opérateur W)
 - Connaissance expertes (valeurs figées, bornes, critères de comparaison des profils)


➡ NMF **informée** (Delmaire *et al.*, 2008–2017)

Questions ouvertes

- Variabilité des sources au cours des saisons ?
- Influence des conditions météo ?

Factorisation matricielle et réseau de neurones (1)

- la NMF a été aussi très utilisée en **apprentissage supervisé** (*machine learning*)
 - On apprend S d'une factorisation $X_1 = A \cdot S$ (son ou image spécifique)
 - On utilise cette matrice dans une autre factorisation : $X_2 = G \cdot S + F \cdot H$
- En apprentissage supervisé, on utilise depuis longtemps les réseaux de neurones
- Quel est le lien entre une factorisation matricielle et un réseau de neurones ?




Source: Flener & Hunter, 2015

Factorisation matricielle et réseau de neurones (2)


La révolution du *deep learning*

- Jusqu'aux années 2005, réseaux de neurones utilisés avec peu de couches (coût calculatoire)
- Machines plus performantes ➡ Plus de couches
- ➡ Des performances inégalées (au prix d'un apprentissage sur une énorme quantité de données)

Simple Neural Network



Deep Learning Neural Network



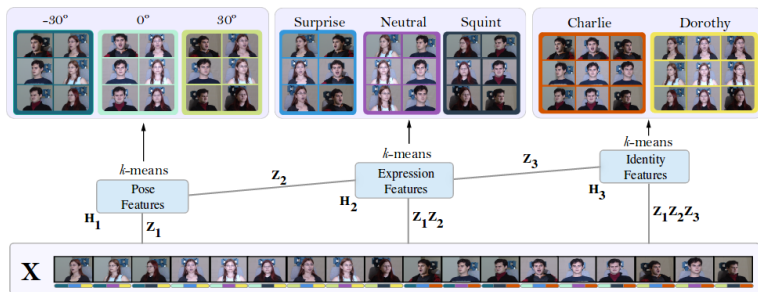
● Input Layer ● Hidden Layer ● Output Layer

Source: <https://goo.gl/kwoJ18>

Deep NMF

- Si une couche de réseau de neurone \simeq 1 NMF
- Pourquoi ne pas faire des NMF successives
- ➡ Deep (semi-)NMF (cf littérature avec le sujet du projet)

Deep NMF pour la séparation de sources chimiques ?



Source: Trigeorgis *et al.*, 2014

- Deep (semi-)NMF extraie des informations structurantes à chaque couche de factorisation (similarités avec classification hiérarchique)
- Est-ce que ce type de factorisation profonde peut apporter un plus pour la séparation de sources chimiques (conditions climatiques, phénomènes saisonniers, etc) ?
- Eventuellement, peut-on proposer des approches **informées** de *Deep NMF*?

Objectifs

- 1 Lire et comprendre la littérature
- 2 Commencer à prendre en main/programmer des méthodes de Deep NMF – dont (Trigeorgis *et al.*, 2014)
<https://github.com/trigeorgis/Deep-Semi-NMF>
- 3 Rajouter l'influence de la pondération de W dans ces approches
- 4 Tester ces approches sur des données de pollution chimique

Y parvenir

- Première réunion formelle où vous présenterez à l'équipe ce que vous avez lu/compris
- Réunions informelles pour discuter de votre avancement
- Programmation de préférence pour Matlab, Python ou C (communautés)
- Stockage de vos codes sur le service Git de l'ULCO

Questions ?